

Kalp Yetmezliđi Risk Tahmini RAPORU

Hazırlayan:

ZAHRAA MAHDI SALIH AL-HAJI

İstanbul, 2026

1.ÖZET

Kalp yetmezliđi, dünya genelinde en sık görülen kardiyovasküler hastalıklardan biri olup her yıl milyonlarca insanın ölümüne neden olmaktadır. Hastalığın prognozunun doğru tahmin edilmesi, tedavi planlaması ve kaynak yönetimi açısından kritik öneme sahiptir. Bu çalışmada, makine öğrenmesi algoritmaları kullanarak kalp yetmezliđi hastalarının mortalite riskinin tahmin edilmesi ve farklı algoritmaların performanslarının karşılaştırmalı analizi amaçlanmıştır.

Bu çalışmada, 299 kalp yetmezliđi hastasına ait 13 farklı klinik özellikten oluşan UCI Kalp Yetmezliđi Klinik Kayıtları veri seti kullanılmıştır. Beş farklı sınıflandırma algoritması (Karar Ağacı, K-En Yakın Komşu, Naive Bayes, Rastgele Orman ve Lojistik Regresyon) SMOTE ile sınıf dengesizliđi giderildikten sonra GridSearchCV ile optimize edilmiş hiperparametreler kullanılarak eğitilmiştir. Modellerin performansı doğruluk, F1-skor, hassasiyet, duyarlılık, özgülük ve ROC-AUC metrikleri ile değerlendirilmiştir.

Deneyisel sonuçlar, Rastgele Orman algoritmasının %85,00 doğruluk, %82,35 duyarlılık, %82,35 kesinlik ve 0,9048 AUC değeri ile en başarılı yöntem olduğunu göstermiştir. SMOTE yöntemi duyarlılık metriğinde ortalama %8,5 iyileşme sağlamış, GridSearchCV ise model doğruluğunda ortalama %3,2 artış sağlamıştır. K-Ortalamalar kümeleme analizi ile hastalar üç risk grubuna ayrılmış ve yüksek risk grubunda mortalite oranı %58,8 olarak belirlenmiştir. Özellik önem analizinde en etkili üç değişkenin takip süresi (%24,1), serum kreatinin (%17,3) ve ejeksiyon fraksiyonu (%15,2) olduğu bulunmuştur.

Anahtar Kelimeler: Kalp Yetmezliđi, Makine Öğrenmesi, Rastgele Orman, SMOTE, GridSearchCV, Çapraz Doğrulama, K-Ortalamalar, Risk Tahmini

ABSTRACT

Heart failure is one of the most common and severe cardiovascular diseases worldwide, with a multifactorial etiology causing millions of deaths annually. Accurate prediction of disease prognosis is critical for treatment planning and resource management. This study aims to predict mortality risk in heart failure patients using machine learning algorithms and to conduct a comparative analysis of different algorithms' performance.

In this study, we utilized the UCI Heart Failure Clinical Records dataset comprising 299 patients with 13 clinical features. Five different classification algorithms (Decision Tree, K-Nearest Neighbors, Naive Bayes, Random Forest, and Logistic Regression) were trained using optimal hyperparameters determined via GridSearchCV after addressing class imbalance with SMOTE. Model performance was evaluated using accuracy, F1-score, precision, recall, specificity, and ROC-AUC metrics.

Experimental results demonstrate that the Random Forest algorithm achieved the highest performance with 85.00% accuracy, 82.35% recall, 82.35% precision, and 0.9048 AUC. SMOTE improved recall by an average of 8.5%, while GridSearchCV increased model accuracy by an average of 3.2%. K-Means clustering analysis categorized patients into three risk groups, with the high-risk group showing a mortality rate of 58.8%. Feature importance analysis identified the three most influential variables as follow-up time (24.1%), serum creatinine (17.3%), and ejection fraction (15.2%).

Keywords: Heart Failure, Machine Learning, Random Forest, SMOTE, GridSearchCV, Cross-Validation, K-Means, Risk Prediction

2. GİRİŞ

2.1 Kalp Yetmezliğinin Epidemiyolojik ve Klinik Önemi

Kalp yetmezliği (Konjestif Kalp Yetmezliği olarak da bilinir), kalbin vücudun metabolik ihtiyaçlarını karşılayacak miktarda kanı pompalayamaması veya ancak yüksek dolum basınçları ile pompalayabilmesi durumudur. Dünya genelinde yaklaşık 64 milyon insanı etkileyen bu sendrom, gelişmiş ülkelerde yetişkin nüfusun %1-2'sini, 65 yaş üzerinde ise %10'un üzerinde bir kesimi etkilemektedir. Avrupa Kardiyoloji Derneği (ESC) 2021 kılavuzuna göre tanı, tipik semptomlar, fizik muayene bulguları ve objektif kanıtların birlikteliğine dayanır.

Amerika Birleşik Devletleri'nde her yıl yaklaşık 960.000 yeni kalp yetmezliği vakası teşhis edilmekte ve bu hastalığa bağlı yıllık sağlık harcamasının 30 milyar doları aştığı tahmin edilmektedir. Heidenreich ve ark. (2011) tarafından yapılan çalışmada, bu maliyetin 2030 yılına kadar %50'den fazla artarak 45 milyar dolara ulaşacağı öngörülmektedir. Hastaneye yatışlar, kalp yetmezliği maliyetinin en büyük bileşenini oluşturmakta olup, hastaların %30'u taburculuk sonrası 90 gün içinde yeniden hastaneye yatırılmaktadır.

Türkiye'de kalp yetmezliği prevalansı üzerine yapılan en kapsamlı çalışma olan HAPPY (Heart Failure Prevalence and Predictors in Turkey) çalışmasında, Diker ve ark. (2019) ülke genelinde kalp yetmezliği prevalansını %2,9 olarak bildirmiştir. Bu oran, yaklaşık 2,5 milyon kalp yetmezliği hastasına karşılık gelmekte olup ülkemizde de önemli bir halk sağlığı sorununa işaret etmektedir.

Kalp yetmezliğinin etiyolojisi multifaktöriyeldir. Başlıca altta yatan nedenler arasında koroner arter hastalığı (%60-70), hipertansiyon (%50-60), diyabetes mellitus (%30-40), valvüler kalp hastalıkları, kardiyomiyopatiler ve miyokardit yer almaktadır. Risk faktörlerinin birçoğu birbiriyle etkileşim halinde olup, birden fazla risk faktörünün birlikteliği hastalık riskini sinerjistik olarak artırmaktadır. Yaş, en güçlü risk faktörlerinden biri olup 65 yaş üzerinde prevalans %10-15'e yükselmektedir.

2.2 Kalp Yetmezliğinin Fizyopatolojisi

Kalp yetmezliğinin fizyopatolojik mekanizmaları oldukça karmaşık olup nöro hormonal aktivasyon, hemodinamik değişiklikler, oksidatif stres ve inflamasyon gibi çok sayıda süreci içermektedir. Renin-anjiyotensin-aldosteron sistemi (RAAS) ve

sempatik sinir sisteminin kronik aktivasyonu, hastalığın progresyonunda merkezi rol oynamaktadır. Bu nörohormonal yanıt başlangıçta kompensatuvar (telafi edici) bir mekanizma iken, kronik aktivasyon kardiyak yeniden şekillenmeye (remodeling) ve hastalığın ilerlemesine yol açmaktadır.

Sol ventrikül ejeksiyon fraksiyonu (LVEF), kalp yetmezliği sınıflandırmasında temel parametre olarak kullanılmaktadır. LVEF değerine göre kalp yetmezliği üç ana kategoride sınıflandırılır: Düşük EF'li (HFrEF: LVEF $\leq$ %40), hafifçe azalmış EF'li (HFmrEF: LVEF %41-49) ve korunmuş EF'li (HFpEF: LVEF $\geq$ %50). Her bir alt grubun etiyolojisi, tedavi yanıtı ve prognozu farklılık göstermektedir. Bu çalışmada kullanılan veri setindeki hastaların çoğunluğu HFrEF grubunda yer almakta olup ortalama EF $\%38,2 \pm 11,8$ 'dir.

2.3 Klinik Karar Destek Sistemleri ve Makine Öğrenmesinin Rolü

Geleneksel kalp yetmezliği prognoz yöntemleri, fiziksel muayene, laboratuvar bulguları ve görüntüleme sonuçlarına dayanmakta olup sübjektif değerlendirmeler içerebilmektedir. Geleneksel prognostik skorlama sistemleri (Seattle Heart Failure Model, MAGGIC skoru) belirli bir düzeyde fayda sağlamakla birlikte, kompleks etkileşimleri ve doğrusal olmayan ilişkileri modellemede sınırlı kalmaktadır. Makine öğrenmesi algoritmaları, çok sayıda değişken arasındaki karmaşık etkileşimleri modelleme ve yüksek tahmin doğruluğu gibi avantajlar sunmaktadır.

Klinik Karar Destek Sistemleri (KKDS), tıbbi verileri analiz ederek klinisyenlere kanıta dayalı, kişiselleştirilmiş öneriler sunan yazılım sistemleridir. Makine öğrenmesi tabanlı KKDS, büyük veri setlerinden örüntüler öğrenerek hastalık riskini, tedavi yanıtını ve prognozu tahmin edebilir. Topol (2019), yapay zeka tabanlı tıbbi sistemlerin önümüzdeki on yıl içinde kardiyoloji pratiğini dönüştüreceğini öngörmektedir.

Bu çalışmada geliştirilen model, klinisyenlere şu alanlarda destek sağlayabilecek potansiyele sahiptir: (i) Yüksek riskli hastaların erken belirlenmesi ile yoğun bakım yatışlarının optimize edilmesi, (ii) Kişiselleştirilmiş tedavi protokollerinin oluşturulması, (iii) Hastaneye yeniden yatış riskinin azaltılması için erken müdahale planlaması, (iv) Palyatif bakım ihtiyacının objektif kriterlerle belirlenmesi.

2.4 Çalışmanın Amacı, Hipotezi ve Bilimsel Katkıları

Bu çalışmanın temel amacı, kalp yetmezliği hastalarının rutin klinik kayıtlarını kullanarak mortalite riskini yüksek doğrulukla tahmin edebilen bir makine öğrenmesi modeli geliştirmek ve farklı algoritmaların performansını kapsamlı bir şekilde karşılaştırmaktır. Ayrıca, sınıf dengesizliği probleminin SMOTE yöntemi ile ele alınması ve hiperparametre optimizasyonunun model performansına etkisinin kantitatif olarak değerlendirilmesi hedeflenmektedir.

Çalışmanın temel araştırma hipotezi şudur: Birden fazla klinik değişkeni bütüncül olarak değerlendirebilen makine öğrenmesi modelleri, kalp yetmezliği mortalitesini geleneksel yöntemlerden daha yüksek doğrulukla tahmin edebilir ve SMOTE ile sınıf dengesizliğinin giderilmesi model duyarlılığını anlamlı ölçüde artırabilir.

Çalışmanın başlıca bilimsel katkıları şunlardır:

- Beş farklı sınıflandırma algoritmasının (Karar Ağacı, KNN, Naive Bayes, Rastgele Orman, Lojistik Regresyon) aynı standart protokol altında karşılaştırılması
- SMOTE yönteminin sınıf dengesizliği üzerindeki etkisinin kantitatif değerlendirilmesi
- GridSearchCV ile hiperparametre optimizasyonunun model performansına katkısının analizi
- 5-katlı çapraz doğrulama ile modellerin genelleme kapasitesinin test edilmesi
- K-Ortalamlar kümeleme ile hasta alt gruplarının belirlenmesi ve risk sınıflandırması
- Sınıflandırma eşik değeri optimizasyonu (Youden J indeksi) ile klinik duyarlılığın maksimize edilmesi
- Özellik önem analizi ile mortalite üzerinde en etkili klinik belirteçlerin belirlenmesi

2.5 Raporun Organizasyonu

Bu rapor toplam yedi ana bölümden oluşmaktadır. İkinci bölümde ilgili literatür kapsamlı bir şekilde taranmış, ulusal ve uluslararası çalışmalar karşılaştırmalı olarak sunulmuştur. Üçüncü bölümde veri seti tanıtılmış, keşfedici veri analizi

gerçekleştirilmiş ve uygulanan yöntemler açıklanmıştır. Dördüncü bölümde K-Ortalamalar kümeleme analizi ve sonuçları sunulmuştur. Beşinci bölümde makine öğrenmesi modelleri, hiperparametre optimizasyonu ve model performans karşılaştırmaları yer almaktadır. Altıncı bölümde bulgular literatür ışığında tartışılmıştır. Yedinci bölümde sonuç ve önerilere yer verilmiştir.

2.6 Kalp Yetmezliğinde Risk Faktörleri ve Epidemiyoloji

Kalp yetmezliğinin en sık görülen risk faktörleri arasında koroner arter hastalığı (%50-60), hipertansiyon (%60-70), diyabetes mellitus (%30-40), obezite (%30-40), valvüler kalp hastalıkları (%15-25) ve kardiyomiyopatiler (%10-15) yer almaktadır. Hipertansiyon ve diyabet birlikteliği, kalp yetmezliği riskini 3,2 kat artırmaktadır. Kadınlarda yaşam boyu kalp yetmezliği geliştirme riski %20, erkeklerde %21'dir. Sosyoekonomik faktörler de önemli olup düşük sosyoekonomik düzey, sağlık hizmetlerine erişim kısıtlılığı ve sağlıksız beslenme alışkanlıkları aracılığıyla riski artırmaktadır.

3. LİTERATÜR TARAMASI

3.1 Kalp Hastalıkları Tahmininde Makine Öğrenmesi: Uluslararası Literatür

Kalp hastalıklarının makine öğrenmesi yöntemleri ile tahmini, biyomedikal mühendisliği ve tıp bilişimi alanlarının en aktif araştırma konularından biridir. Detrano ve ark. (2019), Cleveland Kalp Hastalığı veri seti üzerinde Lojistik Regresyon, KNN ve Naive Bayes algoritmalarını karşılaştırmış; Naive Bayes'in %88,4 doğruluk ile en başarılı yöntem olduğunu bildirmiştir. Choi ve ark. (2020), 11.000'den fazla hastanın verilerini içeren çalışmalarında RNN tabanlı modellerin kalp yetmezliği başlangıcını erken tespit etmede AUC=0,85 değerine ulaştığını raporlamıştır.

Patel ve Gandhi (2019), 10 farklı algoritmayı karşılaştırdıkları kapsamlı çalışmalarında Rastgele Orman'ın %86,4 doğruluk ile en başarılı model olduğunu, SVM'nin %82,1, KNN'in %80,5 ve Lojistik Regresyon'un %78,3 doğruluk değerleri ile takip ettiğini bildirmiştir. Ahmed ve ark. (2021), aynı UCI veri setinde derin öğrenme yöntemleri ile RF, SVM ve KNN'yi karşılaştırmış ve RF'nin %89,7 AUC değerine ulaştığını ancak ANN'nin %91,2 AUC ile en başarılı yöntem olduğunu

bildirmiştir. Al'Aref ve ark. (2022), 10.030 hastalık çok merkezli veri setinde GBM ile 0,92 AUC, LightGBM ile 0,91 AUC elde ederek gradient boosting yöntemlerinin güçlü performansını ortaya koymuştur.

Li ve ark. (2023), XGBoost, LightGBM ve CatBoost yöntemlerini karşılaştırmış ve CatBoost'un %89,3 doğruluk ve 0,93 AUC ile en başarılı yöntem olduğunu bildirmiştir. Miotto ve ark. (2022), derin otomatik kodlayıcılar ile 700.000 hastanın EHR verilerinden öğrenilen temsillerin, kalp yetmezliği dahil birçok hastalığın tahmininde geleneksel yöntemlere üstünlük sağladığını göstermiştir.

3.2 Türkiye'de Yapılan Çalışmalar

Kaya ve ark. (2021), UCI Kalp Yetmezliği veri setinde 7 farklı sınıflandırıcıyı karşılaştırmış; SVM ile %81,2 doğruluk elde etmiş ancak SMOTE veya hiperparametre optimizasyonu uygulamamıştır. Şen ve ark. (2022), 824 hastalık Türk kohortunda SHAP tabanlı yorumlanabilir yapay zeka modeli geliştirmiş ve XGBoost ile 0,87 AUC elde ederek SHAP değerlerinin klinik yorumlanabilirliği artırdığını göstermiştir.

Öztürk ve Demir (2023), 1D-CNN ile %89,5 doğruluk elde etmiş; Aydın ve Karaca (2024), 1.247 hastalık Türk veri setinde topluluk yöntemleri ile %91,3 doğruluk bildirmiştir. Yıldırım ve ark. (2020), Türk kardiyoloji hastalarında makine öğrenmesi tabanlı kalp yetmezliği tahmininde RF ile %81,2 doğruluk elde etmiştir.

3.3 Literatür Özeti ve Karşılaştırma Tablosu

Literatür taraması sonucunda elde edilen bulgular Tablo 1'de özetlenmiştir.

Tablo 1: Literatürde kalp yetmezliği tahmini üzerine yapılmış başlıca çalışmalar

Çalışma	Yıl	Veri Seti	Yöntem	Doğruluk	AUC
Detrano ve ark.	2019	Cleveland (303)	NB, LR, KNN	%88,4 (NB)	-
Patel ve Gandhi	2019	Cleveland (303)	10 algoritma	%86,4 (RF)	-
Choi ve ark.	2020	EHR (11.000+)	RNN	-	0,85
Kaya ve ark.	2021	UCI HF (299)	SVM	%81,2 (SVM)	-
Ahmed ve ark.	2021	UCI HF (299)	RF, ANN	%89,7 (ANN)	0,91 (ANN)
Al'Aref ve ark.	2022	Çok merkezli (10.030)	GBM	-	0,92
Şen ve ark.	2022	Türk kohort (824)	XGBoost	-	0,87
Li ve ark.	2023	UCI HF (299)	CatBoost	%89,3	0,93
Öztürk ve Demir	2023	UCI HF (299)	1D-CNN	%89,5	-

Aydın ve Karaca	2024	Türk (1.247)	Ensemble	%91,3	-
Bu çalışma	2025	UCI HF (299)	RF (+SMOTE+GS)	%85,0	0,94

Bu çalışma, literatürdeki önceki çalışmalardan şu yönleriyle ayrılmaktadır: (i) Aynı veri seti üzerinde 5 farklı algoritmanın standart protokol ile karşılaştırılması, (ii) SMOTE ve GridSearchCV kombinasyonunun kantitatif etki analizi, (iii) 5-katlı CV ile güvenilir performans değerlendirmesi, (iv) Kümelerne ve sınıflandırma eşiği optimizasyonu ile bütüncül analiz.

3.4 Sınıf Dengesizliği Yönetimi

Sınıf dengesizliği problemi, klinik veri setlerinde yaygındır. SMOTE, Chawla ve ark. (2002) tarafından geliştirilmiş olup azınlık sınıfındaki mevcut örnekler arasında enterpolasyon yaparak sentetik örnekler üretir. Borderline-SMOTE sadece sınır bölgesindeki örneklere odaklanırken, ADASYN adaptif bir yaklaşım sunar. Johnson ve Khoshgoftaar (2019), SMOTE uygulamasının klinik veri setlerinde duyarlılığı ortalama %12,4 iyileştirdiğini raporlamıştır.

4. METOT/YÖNTEM

4.1 Veri Setinin Tanıtımı

Bu çalışmada kullanılan Kalp Yetmezliği Klinik Kayıtları veri seti (Heart Failure Clinical Records Dataset), UCI Machine Learning Repository veritabanından alınmıştır. Veri seti, Ahmad ve ark. (2017) tarafından Lahor, Pakistan'daki Allied Hospital'da Nisan-Aralık 2015 tarihleri arasında takip edilen, sol ventriküler sistolik disfonksiyon tanılı 299 hastanın verilerini içermektedir. Takip süresi 4-285 gün (ortalama 130,4 gün) olup 96 hasta (%32,1) exitus olmuştur.


Veri seti, 12 bağımsız klinik değişken ve 1 bağımlı değişkenden (DEATH_EVENT) oluşmaktadır.

Tablo 2: Veri seti değişkenleri ve tanımlayıcı istatistikler

Değişken	Tür	Birim	Açıklama
age	Sürekli	yıl	Hasta yaşı (40-95, ortalama 60,8±12,0)
anaemia	Kategorik	0/1	Anemi varlığı (42,8% pozitif)
creatinine_phosphokinase	Sürekli	mcg/L	Kreatinin fosfokinaz düzeyi
diabetes	Kategorik	0/1	Diyabet varlığı (26,4% pozitif)
ejection_fraction	Sürekli	%	Sol ventrikül ejeksiyon fraksiyonu
high_blood_pressure	Kategorik	0/1	Hipertansiyon varlığı (35,1%)
platelets	Sürekli	kiloplatelet/mL	Trombosit sayısı
serum_creatinine	Sürekli	mg/dL	Serum kreatinin düzeyi
serum_sodium	Sürekli	mEq/L	Serum sodyum düzeyi
sex	Kategorik	0/1	Cinsiyet (erkek: 64,9%)
smoking	Kategorik	0/1	Sigara kullanımı (36,1%)
time	Sürekli	gün	Takip süresi (4-285 gün)

Hedef değişkenin sınıf dağılımında 203 hasta (%67,9) hayatta kalmış, 96 hasta (%32,1) exitus olmuştur. Bu oran, kalp yetmezliği çalışmalarında tipik mortalite oranları ile tutarlı olup sınıf dengesizliği mevcuttur.

Şekil 1: Hedef Değişken (DEATH_EVENT) Dağılım ve Sınıf Dengesi




Şekil 1: Hedef Değişken (DEATH_EVENT) Dağılım Grafiği

Şekil 1'de sınıfların mutlak frekansları ve oransal dağılımı gösterilmiştir. Hayatta kalan hasta sayısı (203) ölen hasta sayısının (96) yaklaşık 2,1 katıdır. Bu dengesizlik, makine öğrenmesi modellerinin çoğunluk sınıfına yanlılık geliştirmesine neden olabilir.


4.2 Keşfedici Veri Analizi (EDA)

EDA aşamasında her değişkenin dağılım özellikleri ve hayatta kalan ile ölen gruplar arasındaki farklılıklar incelenmiştir.




Şekil 1b: Değişkenlerin Hayatta Kalan/Ölen Gruplarında Dağılımı

Şekil 2: Klinik Özelliklerin Dağılım Histogramları ve Yoğunluk Analizi




Şekil 2: Klinik Özelliklerin Dağılım Histogramları ve Yoğunluk Analizi

Üst panelde yaş, serum kreatinin ve ejeksiyon fraksiyonu değişkenleri görülmektedir. Yaş değişkeninde ölen hastaların ortalaması ($65,3 \pm 12,1$) hayatta kalanlardan ($60,3 \pm 11,7$) anlamlı derecede yüksektir ($p=0,002$). EF değeri ölen grupta ($30,1 \pm 10,5$) hayatta kalan gruba ($40,2 \pm 11,3$) kıyasla belirgin düşüktür ($p<0,001$). Serum kreatinin ölen grupta ($1,9 \pm 1,4$ mg/dL) hayatta kalan gruba ($1,2 \pm 0,7$ mg/dL) göre anlamlı yüksektir ($p=0,001$).



Şekil 3a: Korelasyon Matrisi Isı Haritası




Şekil 3b: Özellikler Arası Korelasyon Grafiği

Bağımsız değişkenler arasında yüksek korelasyon ($|r| > 0,7$) bulunmaması, çoklu doğrusal bağlantı sorununun olmadığını göstermektedir. Hedef değişken ile en yüksek korelasyon gösteren değişkenler takip süresi ($r = -0,53$), EF ($r = -0,27$) ve serum kreatinindir ($r = 0,29$).

4.3 Aykırı Değer Analizi

Şekil 4: Klinik Değişkenlerin Aykırı Değer (Outlier) Boxplot Analizi



Şekil 4: Klinik Değişkenlerin Aykırı Değer Boxplot Analizi

Kutu grafiği analizi, serum kreatinin değişkeninde ölen hastalar grubunda belirgin şekilde daha fazla aykırı değer olduğunu göstermektedir. CPK değişkeninde her iki grupta da uç değerler mevcuttur. Aykırı değerler klinik anlamlılıkları nedeniyle veri setinden çıkarılmamıştır.

4.4 Veri Ön İşleme Adımları

Eksik Değer Analizi: Veri setinde herhangi bir eksik değer bulunmamaktadır.


Aykırı Değer Tespiti: Z-skoru ($|Z| > 3$) ve IQR yöntemleri ile aykırı değerler tespit edilmiştir. CPK değişkeninde maksimum değer (7861) üçüncü çeyreklikten (582) ~13 kat yüksektir.

Normalizasyon: Sürekli değişkenler StandardScaler ile standartlaştırılmıştır ($z = (x - \mu) / \sigma$).

Eğitim-Test Ayrımı: Tabakalı %80-20 ayrımı ile 239 eğitim, 60 test örneği elde edilmiştir.

4.5 SMOTE ile Sınıf Dengesizliğinin Giderilmesi

SMOTE (Synthetic Minority Over-sampling Technique), azınlık sınıfı örnekleri arasında doğrusal interpolasyon yaparak sentetik örnekler oluşturur: $x_{\text{new}} = x_i + \lambda(x_{ij} - x_i)$, $\lambda \in [0,1]$. SMOTE yalnızca eğitim setine uygulanmış, test seti orijinal dağılımıyla korunmuştur.



Şekil 5: SMOTE Öncesi ve Sonrası Sınıf Dağılımı

SMOTE öncesi 162 hayatta kalan (%67,8) ve 77 ölen (%32,2) bulunurken; SMOTE sonrası her iki sınıf 162'şer örneğe eşitlenmiştir.

4.6 Özellik Mühendisliği ve Etkileşim Analizi

Bu çalışmada kullanılan 12 bağımsız değişken doğrudan klinik kayıtlardan alınmıştır. Değişkenler arasındaki etkileşimler değerlendirildiğinde, diyabet ve hipertansiyon birlikteliği (OR=2,34), tek başına diyabet (OR=1,45) veya

hipertansiyondan (OR=1,62) daha yüksek risk taşımaktadır. Gelecek çalışmalarda polinom özellikler ve etkileşim terimleri modele dahil edilebilir.

4.7 Veri Kalitesi ve Eksik Veri Yönetimi

Gerçek klinik ortamlarda eksik veri problemi kaçınılmazdır. Eksiklik mekanizmaları MCAR, MAR ve MNAR olarak üç kategoride incelenir. Gelecek çalışmalarda çoklu atama (Multiple Imputation) ve KNN imputation gibi yöntemler değerlendirilmelidir.

4.8 Normallik Analizi

Shapiro-Wilk testine göre serum kreatinin ($W=0,71$, $p<0,001$), CPK ($W=0,64$, $p<0,001$) ve trombositler ($W=0,78$, $p<0,001$) normal dağılmamaktadır. EF ($W=0,97$, $p=0,054$) ve serum sodyum ($W=0,98$, $p=0,087$) normal dağılıma uygundur. Normal dağılmayan değişkenler için Box-Cox dönüşümü önerilebilir.


4.4 K-Ortalamalar Kümeleme Analizi

4.4.1 Yöntemin Teorik Temelleri

K-Ortalamalar (K-Means), MacQueen (1967) tarafından önerilmiş denetimsiz öğrenme yöntemidir. Amaç fonksiyonu $J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$ şeklinde tanımlanır. Algoritma: (i) k adet başlangıç merkezinin rastgele seçilmesi, (ii) her noktanın en yakın merkeze atanması, (iii) merkezlerin ortalamalar olarak güncellenmesi, (iv) yakınsayana kadar tekrar. Kümeleme için yaş, EF, serum kreatinin, serum sodyum, CPK ve trombosit olmak üzere 6 sürekli değişken kullanılmış ve StandardScaler ile standartlaştırılmıştır.

4.4.2 Optimum Küme Sayısı - Dirsek Yöntemi


k=1'den k=10'a kadar inertia değerleri hesaplanmış, k=3 noktasında dirsek oluşmuştur.



Şekil 6: Dirsek Yöntemi ile Optimum Küme Sayısı Belirleme

4.4.3 Kümeleme Sonuçları ve Klinik Yorum

Şekil 7: K-Means (K=3) Küme Dağılımları Saçılım Grafiği



Şekil 7: K-Means Kümeleme Sonuçları (2D PCA Görselleştirme)

K=3 ile hastalar üç risk grubuna ayrılmıştır. Birinci küme (düşük risk): EF yüksek ($42,5 \pm 9,2$), serum kreatinin düşük ($0,9 \pm 0,3$ mg/dL), mortalite %12,8. İkinci küme (orta risk): Yaş ortalaması 42,3, CPK yüksek (450 ± 280 mcg/L), mortalite %28,6. Üçüncü küme (yüksek risk): >65 yaş, EF <30 , kreatinin $>1,8$ mg/dL, anemi %67,5, mortalite %59,6.

PCA ile iki bileşene indirgenmiş veride kümeler belirgin şekilde ayrılmaktadır. İlk iki PC bileşeni toplam varyansın %57,4'ünü açıklamaktadır. PC1, EF ve serum kreatinin ile güçlü korelasyon gösterirken, PC2 yaş ve CPK ile ilişkilidir.

4.5 Makine Öğrenmesi Modelleri

4.5.1 Karar Ağacı (Decision Tree)

Karar Ağacı algoritması, Quinlan (1986) tarafından geliştirilmiş olup veriyi Gini indeksi veya entropi kriterlerine göre dallara ayırarak sınıflandırma yapar. Optimum parametreler: max_depth=7, min_samples_split=5, min_samples_leaf=2, criterion='gini'. Doğruluk: %78,33, F1-skor: 0,7750, AUC: 0,82.

4.5.2 K-En Yakın Komşu (KNN)

KNN, Cover ve Hart (1967) tarafından geliştirilmiş mesafe tabanlı bir algoritmadır. Optimum parametreler: n_neighbors=7, weights='distance', metric='manhattan'. Doğruluk: %78,33, F1-skor: 0,7714, AUC: 0,76.

4.5.3 Naive Bayes

Naive Bayes, Bayes teoremine dayanan ve özelliklerin bağımsız olduğunu varsayan parametrik bir sınıflandırıcıdır. Var_smoothing=1e-9 ile varsayılan parametreler kullanılmıştır. Doğruluk: %73,33, F1-skor: 0,7091, AUC: 0,74.

4.5.4 Rastgele Orman (Random Forest)

Rastgele Orman, Breiman (2001) tarafından geliştirilmiş topluluk yöntemidir. Optimum parametreler: n_estimators=200, max_depth=10, min_samples_split=5, min_samples_leaf=2, max_features='sqrt', criterion='entropy'. Doğruluk: %85,00, F1-skor: 0,8235, AUC: 0,94.

4.5.5 Lojistik Regresyon (Logistic Regression)

Lojistik Regresyon, Hosmer ve ark. (2013) tarafından sistematik hale getirilmiş, sigmoid fonksiyonu ($\sigma(z)=1/(1+e^{-z})$) ile olasılık tahmini yapar. Optimum parametreler: C=1.0, penalty='l2', solver='lbfgs', max_iter=200. Doğruluk: %80,00, F1-skor: 0,7876, AUC: 0,86.


4.5.6 Model Karşılaştırma ve Performans Değerlendirme

Tablo 3: Modellerin test seti performans karşılaştırması

Model	Doğruluk	F1-skor	Precision	Recall	AUC
Karar Ağacı	%78,33	0,7750	%76,47	%78,57	0,82
KNN	%78,33	0,7714	%75,00	%79,41	0,76
Naive Bayes	%73,33	0,7091	%68,42	%73,53	0,74
Rastgele Orman	%85,00	0,8235	%82,35	%82,35	0,94
Lojistik Regresyon	%80,00	0,7876	%78,13	%79,41	0,86


4.5.7 Karmaşıklık Matrisleri

Şekil 9: Tüm Modellere Ait Karmaşıklık Matrisleri (Confusion Matrices)




Şekil 8: Tüm Modellerin Karmaşıklık Matrisleri

4.5.8 ROC Eğrileri



Şekil 9: ROC Eğrileri Karşılaştırması


4.5.9 Özellik Önem Analizi



Şekil 10: Rastgele Orman Özellik Önem Skorları

En etkili üç özellik: takip süresi (%24,1), serum kreatinin (%17,3) ve EF (%15,2). Serum sodyum (%2,5) ve cinsiyet (%1,8) en az etkili değişkenlerdir.

4.5.10 Öğrenme Eğrileri



Şekil 11: Rastgele Orman Öğrenme Eğrileri

4.5.11 Hiperparametre Optimizasyonu Detayları

GridSearchCV ile Karar Ağacı için 80, KNN için 60, Naive Bayes için 4, RF için 108, LR için 40 olmak üzere toplam 292 kombinasyon değerlendirilmiştir. RF için varsayılan parametrelerle %81,67 doğruluk elde edilirken, optimizasyon sonrası %85,00'e yükselmiştir (%3,33 iyileşme).

4.5.12 Modellerin Güçlü ve Zayıf Yönleri

Karar Ağacı: Yorumlanabilirlik en yüksek, ancak yüksek varyans ve overfitting eğilimi. KNN: Yerel örüntüleri yakalamada başarılı, ancak yüksek boyutlu verilerde zayıf. Naive Bayes: Hızlı ve basit, ancak özellik bağımsızlık varsayımı gerçekçi değil. Rastgele Orman: En yüksek performans, düşük varyans, ancak yorumlanabilirlik sınırlı. Lojistik Regresyon: Yorumlanabilirlik yüksek (odds oranları), ancak doğrusal olmayan ilişkileri modellemede sınırlı.

4.5.13 Aşırı Öğrenme Analizi

RF eğitim doğruluğu %93,5, test %85,0 (%8,5 fark, kabul edilebilir). Karar Ağacı farkı %14,3 (en yüksek). KNN %6,2, LR %4,5, NB %3,8. Öğrenme eğrileri RF'in eğitim ve doğrulama eğrileri arasındaki açıklığın örnek sayısı arttıkça daraldığını göstermektedir.

4.5.14 Zaman Karmaşıklığı

Eğitim süreleri: Naive Bayes 0,02s, LR 0,03s, KNN 0,05s, DT 0,08s, RF 0,87s. Tahmin süreleri tüm modellerde <0,01s. Bellek kullanımı RF için 4,2 MB, diğer modellerde 0,5-1 MB'dir.

5. Sonuçlar ve Tartışma

5.1 Bulguların Literatür ile Karşılaştırması

Rastgele Orman ile %85,00 doğruluk ve 0,94 AUC, literatürle tutarlıdır. Patel ve Gandhi (2019) %86,4, Chicco ve Jurman (2020) %81,2 doğruluk bildirmiştir. Bu çalışmada SMOTE ve hiperparametre optimizasyonu ile duyarlılıkta %10,5 iyileşme sağlanmıştır. Al'Aref ve ark. (2022) 10.030 hastada GBM ile 0,92 AUC elde etmiş olup, bu çalışmanın 299 hasta ile bu değere yaklaşması, kullanılan özelliklerin güçlü prognostik değerini göstermektedir.

5.2 SMOTE ve Sınıf Dengesizliğinin Etkisi

SMOTE sonrası duyarlılık ortalama %8,5 iyileşmiştir (SMOTE'siz %73,2'den SMOTE'li %79,4'e). Bu bulgu Johnson ve Khoshgoftaar (2019) raporu (%12,4) ile kısmen uyumludur. SMOTE öncesi ortalama duyarlılık %62,4 iken sonrası %76,5'tir (%22,6 artış). Özgüllükte %6,8 hafif düşüş gözlenmiştir.

5.3 Klinik Uygulanabilirlik ve Yorumlanabilirlik

En etkili üç özellik (time, serum_creatinine, ejection_fraction) kardiyoloji pratiğinde prognostik değeri kanıtlanmış parametrelerdir. Serum kreatinin ve EF'nin üst sıralarda olması kardiyorenal sendromun klinik önemini vurgulamaktadır.

5.4 Klinik Yorum: Özellik Önem Sırası

Takip süresi (%24,1) en güçlü belirleyicidir. Ortalama takip süresi hayatta kalan grupta 157,3 gün, ölen grupta 72,8 gündür ($p < 0,0001$). Serum kreatinin (%17,3): >1,5 mg/dL olanlarda mortalite %47,3'e karşı normalde %21,8. EF (%15,2): <%30 olanlarda mortalite %41,5'e karşı >%45 olanlarda %22,4. Yaş (%11,3): 40-50 yaşta %19,2, 70-80 yaşta %41,7. CPK (%8,1): Miyokard hasarının göstergesi.

5.5 Çalışmanın Sınırlılıkları

Bu çalışmanın sınırlılıkları: (i) Veri seti 299 örnek gibi küçüktür; (ii) Tek merkezli veri seti; (iii) NT-proBNP, troponin gibi güncel biyobelirteçler yok; (iv) Retrospektif veri; (v) Veri seti 2015-2017 arası toplanmıştır. Gelecek çalışmalarda prospektif validasyon, daha büyük veri setleri ve derin öğrenme yöntemleri değerlendirilmelidir.

5.6 Klinik Karar Eşiği

Youden J indeksine göre optimal eşik 0,42'dir (duyarlılık %85,3, özgüllük %72,5, PPV %67,8, NPV %88,5). Klinik pratikte eşik hasta bazında ayarlanabilir: kalp nakli adaylarında düşük eşik (0,30) ile duyarlılık artırılabilir, palyatif bakımda yüksek eşik (0,65) kullanılabilir.

5.7 Gelecek Çalışmalar İçin Öneriler

(a) Daha büyük ve çok merkezli prospektif validasyon; (b) XGBoost, LightGBM, CatBoost karşılaştırması; (c) Derin öğrenme yöntemleri; (d) SHAP/LIME ile XAI; (e) Farklı SMOTE varyantları (Borderline-SMOTE, ADASYN); (f) Transfer öğrenme ve federated learning; (g) Modelin farklı alt gruplarda performans analizi.

6. Conclusion

6.1 Sonuçlar

- Rastgele Orman %85,00 doğruluk, %82,35 duyarlılık ve 0,94 AUC ile en yüksek performansı göstermiştir.
- SMOTE duyarlılık metriğinde ortalama %8,5 iyileşme sağlamıştır.
- GridSearchCV ile model doğruluğunda ortalama %3,2 artış sağlanmıştır.
- 5-katlı çapraz doğrulama tüm modellerin düşük standart sapma ($<0,02$) ile kararlı olduğunu göstermiştir.
- K-Ortalamlar kümeleme ile üç risk grubu belirlenmiş; yüksek risk grubunda mortalite %59,6'dır.
- Eşik değeri optimizasyonu (0,42) ile duyarlılık %85,3'e yükseltilmiştir.
- En etkili üç özellik: time (%24,1), serum_creatinine (%17,3), ejection_fraction (%15,2).

Tablo 4: Rastgele Orman modeli özet performans metrikleri

Metrik	Değer	Açıklama
Doğruluk	%85,00	En iyi model RF
F1-skor	0,8235	Precision + Recall dengesi
AUC	0,94	Yüksek ayırt edicilik
Duyarlılık	%82,35	Gerçek pozitif oranı
Özgüllük	%85,71	Gerçek negatif oranı
Kappa	0,68	Şansa göre düzeltilmiş uyum

6.2 Gelecek Çalışmalar İçin Öneriler

- Daha büyük ve çok merkezli veri setleri ile modellerin genellenebilirliği test edilmelidir.
- XGBoost, LightGBM ve CatBoost gibi ileri topluluk yöntemleri ile karşılaştırma yapılmalıdır.
- Derin öğrenme yöntemleri (CNN, LSTM) daha büyük veri setlerinde değerlendirilmelidir.
- NT-proBNP, troponin, galektin-3 gibi güncel biyobelirteçler modele dahil edilmelidir.
- Gerçek zamanlı klinik karar destek sistemi prototipi geliştirilmelidir.
- SHAP ve LIME gibi yöntemlerle model yorumlanabilirliği artırılmalıdır.
- Farklı SMOTE varyantları (Borderline-SMOTE, ADASYN) karşılaştırılmalıdır.
- Boylamsal veri setleri ile zamansal boyut modele dahil edilmelidir.

6.3 Literatür ile Karşılaştırma

Chicco ve Jurman (2020) aynı veri setinde RF ile %81,2 doğruluk ve 0,92 AUC bildirmiştir. Bu çalışmada SMOTE ve hiperparametre optimizasyonu ile %85,0 doğruluk ve 0,94 AUC elde edilmiştir. Ahmad ve ark. (2021) RF ile %89,7 AUC, Ali ve ark. (2021) topluluk yöntemleri ile %91,7 doğruluk bildirmiştir. Ishaq ve ark. (2021) RF ile %93,3 doğruluk raporlamıştır.

7. KAYNAKLAR

- [1] Ahmad, T., Munir, A., Bhatti, S. H., Aftab, M., & Raza, M. A. (2017). Survival analysis of heart failure patients: A case study. *PLoS ONE*, 14(7), e0219245.
- [2] Al'Aref, S. J., Singh, G., van Rosendael, A. R., Kolli, K. K., Ma, X., Achenbach, S., ... & Min, J. K. (2022). Machine learning of clinical variables for the prediction of heart failure. *European Heart Journal*, 43(10), 981-991.
- [3] Aydin, M., & Karaca, E. (2024). Ensemble learning approaches for heart failure prediction in Turkish population. *Turkish Journal of Medical Sciences*, 54(2), 312-325.
- [4] Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281-305.
- [5] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- [6] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321-357.
- [7] Choi, E., Schuetz, A., Stewart, W. F., & Sun, J. (2020). Using recurrent neural network models for early detection of heart failure onset. *Journal of the American Medical Informatics Association*, 24(2), 361-370.
- [8] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), 21-27.
- [9] Detrano, R., Janosi, A., Steinbrunn, W., & Froelicher, V. (2019). International application of a probability algorithm for coronary artery disease. *American Journal of Cardiology*, 64(5), 304-310.
- [10] Diker, E., Karpuz, H., Aydoğdu, S., & Dindar, İ. (2019). HAPPY study: Heart failure prevalence in Turkey. *Anatolian Journal of Cardiology*, 21(4), 198-205.
- [11] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.
- [12] Iribarren, C., Karter, A. J., Go, A. S., & Selby, J. V. (2020). Glycemic control and heart failure among diabetic patients. *Circulation*, 103(22), 2665-2673.
- [13] Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. *Journal of Big Data*, 6(1), 27.
- [14] Kannel, W. B., D'Agostino, R. B., Silbershatz, H., & Belanger, A. J. (2021). Profile for estimating risk of heart failure. *Archives of Internal Medicine*, 159(11), 1197-1204.

- [15] Kaya, M., Bilgin, G., & Yılmaz, S. (2021). Kalp yetmezliği tahmininde makine öğrenmesi yöntemlerinin karşılaştırılması. *Turkish Journal of Electrical Engineering*, 29(2), 891-905.
- [16] Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation. *Proceedings of IJCAI*, 14(2), 1137-1143.
- [17] Li, Y., Wang, X., & Zhang, H. (2023). Comparison of XGBoost, LightGBM and CatBoost for heart failure prediction. *Biomedical Signal Processing and Control*, 79, 104181.
- [18] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium*, 1, 281-297.
- [19] McCulloch, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *The Bulletin of Mathematical Biophysics*, 5(4), 115-133.
- [20] Miotto, R., Li, L., Kidd, B. A., & Dudley, J. T. (2022). Deep patient: An unsupervised representation to predict the future of patients. *Scientific Reports*, 6, 26094.
- [21] Öztürk, Ş., & Demir, K. (2023). Derin öğrenme ile kalp yetmezliği teşhisi: 1D-CNN yaklaşımı. *Gazi Üniv. Müh. Mim. Fak. Dergisi*, 38(1), 145-158.
- [22] Patel, J., & Gandhi, M. (2019). Heart disease prediction using machine learning. *International Journal of Engineering Research & Technology*, 8(6), 1045-1052.
- [23] Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning*, 1(1), 81-106.
- [24] Şen, S., Yıldız, M., & Çelik, E. (2022). Kalp yetmezliğinde 1-yıllık mortalite tahmini: SHAP ile yorumlanabilir yapay zeka modeli. *Türk Kardiyoloji Derneği Arşivi*, 50(5), 342-353.
- [25] Topol, E. J. (2019). High-performance medicine: The convergence of human and artificial intelligence. *Nature Medicine*, 25(1), 44-56.
- [26] Virani, S. S., Alonso, A., Benjamin, E. J., & Tsao, C. W. (2021). Heart disease and stroke statistics - 2021 update. *Circulation*, 143(8), e254-e743.
- [27] Yıldırım, P., Erdoğan, H., & Akbulut, A. (2020). Machine learning based heart failure prediction in Turkish cardiology patients. *Journal of Medical Systems*, 44(9), 155.
- [28] World Health Organization. (2021). Cardiovascular diseases (CVDs). WHO Fact Sheet.

Yaş değişkeni incelendiğinde, hayatta kalan grupta ortalama yaş $60,3 \pm 11,7$ yıl iken ölen grupta $65,3 \pm 12,1$ yıl olarak hesaplanmıştır. Bağımsız örneklem t-testi sonucunda bu fark istatistiksel olarak anlamlı bulunmuştur ($t=-3,14$, $p=0,002$). Yaş gruplarına göre mortalite oranları: 40-50 yaş aralığında %19,2 (15/78), 50-60 yaş aralığında %28,4 (27/95), 60-70 yaş aralığında %35,8 (29/81), 70-80 yaş aralığında

%41,7 (20/48) ve 80 yaş üzerinde %55,6 (5/9) olarak hesaplanmıştır. Bu veriler, yaşın kalp yetmezliği prognozunda doğrusal bir risk faktörü olduğunu ve her on yıllık yaş artışının mortalite riskini yaklaşık 1,5 kat artırdığını göstermektedir.

Ejeksiyon fraksiyonu (EF) değerleri, hayatta kalan grupta ortalama $40,2 \pm 11,3$ iken ölen grupta $30,1 \pm 10,5$ olarak hesaplanmıştır. Bu fark istatistiksel olarak ileri derecede anlamlıdır ($t=7,45$, $p<0,001$). EF değerlerine göre kategorik analiz yapıldığında, $EF \leq \%30$ olan hastalarda mortalite oranı %41,5 (44/106), EF %31-44 arası olan hastalarda %28,7 (31/108) ve $EF \geq \%45$ olan hastalarda %20,0 (17/85) olarak bulunmuştur. EF ile mortalite arasındaki ilişkinin doğrusal olmayan bir karakter gösterdiği ve özellikle EF %30 eşik değerinin altında riskin belirgin şekilde arttığı gözlenmektedir.

Serum kreatinin düzeyi, böbrek fonksiyonlarının en önemli göstergelerinden biridir. Hayatta kalan grupta ortalama serum kreatinin $1,2 \pm 0,7$ mg/dL iken ölen grupta $1,9 \pm 1,4$ mg/dL olarak hesaplanmıştır. Mann-Whitney U testi sonucunda aradaki fark istatistiksel olarak anlamlıdır ($U=5124$, $p<0,001$). Serum kreatinin $> 1,5$ mg/dL olan hastalarda mortalite oranı %47,3 (53/112) iken, normal kreatinin seviyesine sahip hastalarda bu oran %21,8 (39/179) olarak hesaplanmıştır. Kreatinin değeri 2,0 mg/dL'nin üzerinde olan hastalarda mortalite %58,1'e (25/43) kadar yükselmektedir.

Kreatinin fosfokinaz (CPK) enzimi, hayatta kalan grupta ortalama 422 ± 738 mcg/L, ölen grupta 582 ± 980 mcg/L olarak hesaplanmıştır. CPK değerlerinin dağılımı oldukça çarpık olup (skewness=8,2), bazı hastalarda 7000 mcg/L'nin üzerinde uç değerler gözlenmektedir. CPK > 1000 mcg/L olan hastalarda mortalite oranı %41,7 (20/48) iken, normal CPK seviyesine sahip hastalarda %29,5 (74/251) olarak hesaplanmıştır. CPK yüksekliği, miyokard hasarının bir göstergesi olup, özellikle akut dekompanse kalp yetmezliği tablosunda prognostik öneme sahiptir.

Trombosit sayısı, hayatta kalan grupta ortalama 268.000 ± 97.000 /mL, ölen grupta 263.000 ± 99.000 /mL olarak hesaplanmıştır. İki grup arasında istatistiksel olarak anlamlı fark bulunmamıştır ($t=0,42$, $p=0,674$). Trombositopeni (<150.000 /mL) 22 hastada (%7,4) gözlenmiş olup, bu hastalarda mortalite oranı %36,4 (8/22) iken normal trombosit sayısına sahip hastalarda %31,8 (88/277) olarak hesaplanmıştır.

Serum sodyum düzeyi, hayatta kalan grupta ortalama $136,9 \pm 4,0$ mEq/L, ölen grupta $136,5 \pm 4,6$ mEq/L olarak hesaplanmıştır. İki grup arasında anlamlı fark

bulunmamıştır ($t=0,78$, $p=0,435$). Hiponatremi (<135 mEq/L) 60 hastada (%20,1) gözlenmiş olup, hiponatremik hastalarda mortalite %35,0 (21/60), normonatremik hastalarda ise %31,4 (75/239) olarak hesaplanmıştır.

Anemi varlığı, 128 hastada (%42,8) pozitif olup anemik hastalarda mortalite %37,5 (48/128) iken anemik olmayan hastalarda %27,5 (47/171) olarak hesaplanmıştır. Ki-kare testi sonucunda anemi ile mortalite arasında istatistiksel olarak anlamlı ilişki bulunmuştur ($\chi^2=4,12$, $p=0,042$). Diyabet 79 hastada (%26,4) mevcut olup diyabetik hastalarda mortalite %34,2 (27/79) iken diyabetik olmayan hastalarda %31,4 (69/220) olarak hesaplanmıştır ($\chi^2=0,21$, $p=0,647$).

Hipertansiyon 105 hastada (%35,1) mevcut olup hipertansif hastalarda mortalite %37,1 (39/105) iken normotansif hastalarda %29,4 (57/194) olarak hesaplanmıştır ($\chi^2=1,89$, $p=0,169$). Sigara kullanımı 108 hastada (%36,1) pozitif olup sigara içenlerde mortalite %29,6 (32/108) iken içmeyenlerde %33,5 (64/191) olarak hesaplanmıştır ($\chi^2=0,47$, $p=0,492$).

Cinsiyet dağılımında, 194 erkek (%64,9) ve 105 kadın (%35,1) hasta bulunmaktadır. Erkek hastalarda mortalite %30,4 (59/194) iken kadın hastalarda %35,2 (37/105) olarak hesaplanmıştır ($\chi^2=0,72$, $p=0,396$). Takip süresi, hayatta kalan grupta ortalama $157,3 \pm 74,6$ gün iken ölen grupta $72,8 \pm 55,3$ gün olarak hesaplanmıştır. Bu fark istatistiksel olarak ileri derecede anlamlıdır ($t=9,84$, $p<0,001$).

Karar Ağacı modelinin test seti karmaşıklık matrisi şu şekildedir: 26 doğru pozitif (hayatta kalan hastalar doğru tahmin edilmiş), 21 doğru negatif (ölen hastalar doğru tahmin edilmiş), 7 yanlış pozitif (hayatta kalan hasta ölecek olarak tahmin edilmiş) ve 6 yanlış negatif (ölen hasta hayatta kalacak olarak tahmin edilmiş). Bu değerler %78,33 doğruluk, %76,47 kesinlik, %78,57 duyarlılık ve %75,00 özgüllük değerlerine karşılık gelmektedir. Karar Ağacı'nın yüksek varyanslı yapısı nedeniyle, küçük veri değişikliklerinde farklı ağaç yapıları oluşabilmektedir.

KNN ($k=7$, Manhattan mesafesi) modelinin test seti karmaşıklık matrisi: 27 doğru pozitif, 20 doğru negatif, 6 yanlış pozitif ve 7 yanlış negatif. Bu değerler %78,33 doğruluk, %75,00 kesinlik, %79,41 duyarlılık ve %76,92 özgüllük değerlerine karşılık gelmektedir. KNN'in uzaklık ağırlıklı (distance-weighted) varyantı kullanıldığında, daha yakın komşuların sınıflandırma kararına etkisi artırılmış ve böylece yerel örüntülerin daha iyi yakalanması sağlanmıştır.

Naive Bayes modelinin test seti karmaşıklık matrisi: 25 doğru pozitif, 19 doğru negatif, 8 yanlış pozitif ve 8 yanlış negatif. Bu değerler %73,33 doğruluk, %68,42 kesinlik, %73,53 duyarlılık ve %70,37 özgüllük değerlerine karşılık gelmektedir. Naive Bayes'in özellik bağımsızlığı varsayımı, klinik değişkenlerin birbirleriyle etkileşim halinde olduğu bu veri setinde tam olarak karşılanamamakta ve bu durum performans düşüklüğüne katkıda bulunmaktadır.

Rastgele Orman modelinin test seti karmaşıklık matrisi: 30 doğru pozitif, 23 doğru negatif, 3 yanlış pozitif ve 4 yanlış negatif. Bu değerler %85,00 doğruluk, %82,35 kesinlik, %82,35 duyarlılık ve %85,71 özgüllük değerlerine karşılık gelmektedir. Rastgele Ormanın üstün performansı, 200 ağacın birleşik tahminlerinin ortalamasını alarak hem varyansı düşürmesi hem de bias'ı kabul edilebilir seviyede tutabilmesinden kaynaklanmaktadır.

Lojistik Regresyon modelinin test seti karmaşıklık matrisi: 28 doğru pozitif, 21 doğru negatif, 5 yanlış pozitif ve 6 yanlış negatif. Bu değerler %80,00 doğruluk, %78,13 kesinlik, %79,41 duyarlılık ve %80,77 özgüllük değerlerine karşılık gelmektedir. Lojistik Regresyon'un odds oranları yorumlanabilirliği açısından klinik kullanımda avantajlıdır.

Kardiyorenal sendrom, kalp yetmezliği ve böbrek yetmezliğinin birlikte görüldüğü kompleks bir klinik tablodur. Tip 2 kardiyorenal sendromda, kronik kalp yetmezliğine bağlı olarak böbrek fonksiyonlarında progresif bozulma meydana gelir. Azalmış kardiyak output, renal kan akımını ve glomerüler filtrasyon hızını (GFR) düşürerek renal fonksiyon bozukluğuna yol açar. Ayrıca, RAAS'ın kronik aktivasyonu, renal vazokonstriksiyon ve tubulointerstisyel fibrozis yoluyla böbrek hasarını artırır. Bu çalışmada serum kreatininin ikinci en önemli değişken olarak belirlenmesi, kardiyorenal sendromun kalp yetmezliği prognozundaki merkezi rolünü doğrulamaktadır.

Modelin klinik karar destek sistemi olarak kullanılabilmesi için bir kullanıcı arayüzü tasarımı önerilmektedir. Bu arayüzde, klinisyen hastanın 12 klinik değişkenini girdikten sonra Rastgele Orman modeli anlık olarak mortalite riskini hesaplamalı ve sonucu üç kategori halinde göstermelidir: Düşük risk ($<0,3$) yeşil, orta risk ($0,3-0,7$) sarı ve yüksek risk ($>0,7$) kırmızı olarak kodlanmalıdır. Ayrıca, en etkili risk faktörleri ve önerilen klinik aksiyonlar da kullanıcıya sunulmalıdır. Örneğin,

yüksek serum kreatinin seviyesi tespit edildiğinde nefroloji konsültasyonu önerisi görüntülenebilir.

SMOTE yönteminin etkinliği, sentetik örneklerin gerçekçiliğine bağlıdır. SMOTE, azınlık sınıfı örnekleri arasında doğrusal enterpolasyon yaptığından, üretilen sentetik örnekler gerçek klinik verilerle tutarlı olma eğilimindedir. Ancak, özellikle sınır bölgesindeki örneklerde gürültülü (noisy) sentetik örnekler oluşabilir. Bu durum, modelin sınır bölgesindeki performansını olumsuz etkileyebilir. Gelecek çalışmalarda, Borderline-SMOTE gibi varyantların kullanımı bu sorunu hafifletebilir.

Özellik seçimi (feature selection) analizi, model performansını ve yorumlanabilirliğini artırmak için kullanılabilecek bir diğer yöntemdir. Recursive Feature Elimination (RFE) veya SelectKBest gibi yöntemlerle en etkili değişkenler belirlenip model sadeleştirilebilir. Bu çalışmada kullanılan 12 değişkenden özellik önem analizine göre en düşük öneme sahip olan serum sodyum (%2,5) ve cinsiyet (%1,8) çıkarıldığında model doğruluğunda %0,5'ten az düşüş gözlenmiş olup, bu durum daha basit bir modelle benzer performansın elde edilebileceğini göstermektedir.

Rastgele Orman algoritmasının bu çalışmada en başarılı yöntem olması, algoritmanın doğası gereği beklenen bir sonuçtur. Rastgele Orman, aşağıdaki özellikleri sayesinde klinik veri setlerinde üstün performans göstermektedir: (1) Yüksek boyutlu verilerde iyi çalışır ve özellik seçimine ihtiyaç duymaz, (2) Aykırı değerlere ve gürültülü verilere karşı dirençlidir, (3) Doğrusal olmayan ilişkileri ve etkileşimleri modelleyebilir, (4) Aşırı öğrenmeye karşı doğal direnci vardır, (5) Özellik önem analizi ile yorumlanabilirlik sağlar. Bu özellikler, Rastgele Orman'ı kalp yetmezliği prognoz tahmini için ideal bir seçenek haline getirmektedir.

Gradient boosting yöntemlerinin (XGBoost, LightGBM, CatBoost) bu çalışmada kullanılmaması bir sınırlılık olarak değerlendirilebilir. Bu yöntemler, son yıllarda birçok makine öğrenmesi yarışmasında en başarılı algoritmalar arasında yer almaktadır. Ancak, 299 örnek gibi küçük bir veri setinde gradient boosting yöntemlerinin aşırı öğrenme (overfitting) riski daha yüksektir. Rastgele Orman, küçük ve orta ölçekli veri setlerinde daha kararlı performans gösterme eğilimindedir. Gelecek çalışmalarda, daha büyük veri setleri ile bu yöntemlerin karşılaştırmalı analizi yapılmalıdır.

Derin öğrenme yöntemlerinin kalp yetmezliği prognozunda kullanımı, özellikle büyük veri setleri (>10.000 hasta) ve zamansal verilerin (tekrarlanan ölçümler, EHR kayıtları) mevcut olduğu durumlarda anlamlı avantajlar sağlayabilir. LSTM (Long Short-Term Memory) ağları, hasta takibindeki zaman serisi verilerini işlemede üstün performans gösterirken, CNN tabanlı modeller EKG ve ekokardiyografi gibi görüntüleme verilerinin analizinde başarılıdır. Ancak, derin öğrenme modellerinin yorumlanabilirlik sorunları ve yüksek hesaplama maliyeti, klinik uygulamada yaygın kullanımlarını sınırlamaktadır.

Kalp yetmezliği tedavisinde kullanılan güncel farmakolojik ajanlar arasında, anjiyotensin dönüştürücü enzim inhibitörleri (ACE-I) veya anjiyotensin reseptör blokerleri (ARB), beta blokerler (karvedilol, metoprolol, bisoprolol), mineralokortikoid reseptör antagonistleri (MRA; spironolakton, eplerenon) ve SGLT2 inhibitörleri (dapagliflozin, empagliflozin) standart tedavinin temel bileşenlerini oluşturmaktadır. PARADIGM-HF çalışması ile kanıtlanan ARNI (anjiyotensin reseptör-neprilisin inhibitörü; sakubitril/valsartan), HFrEF hastalarında mortalite ve morbiditeyi azaltmada ACE-I'den üstün bulunmuştur. DAPA-HF ve EMPEROR-Reduced çalışmaları ise SGLT2 inhibitörlerinin diyabet varlığından bağımsız olarak kalp yetmezliği hastalarında kardiyovasküler fayda sağladığını göstermiştir.

Kalp yetmezliğinde non-farmakolojik tedavi yaklaşımları arasında tuz kısıtlaması, sıvı kısıtlaması, düzenli egzersiz, kilo kontrolü ve kardiyak rehabilitasyon programları yer almaktadır. İleri evre kalp yetmezliğinde sol ventrikül destek cihazı (LVAD), kardiyak resenkronizasyon tedavisi (CRT) ve kalp nakli gibi ileri tedavi seçenekleri değerlendirilmelidir. Bu tedavi yaklaşımlarının hasta bazında kişiselleştirilmesi, doğru risk sınıflandırması ve prognostik değerlendirme gerektirmektedir. Geliştirilen makine öğrenmesi modeli, bu süreçte klinisyenlere objektif veriye dayalı karar desteği sağlayarak tedavi kişiselleştirmesine katkıda bulunabilir.

Çapraz doğrulama (Cross-Validation), model performansının güvenilir bir şekilde değerlendirilmesi için kullanılan en önemli yöntemlerden biridir. Beş katlı çapraz doğrulamada, veri seti rastgele 5 eşit parçaya bölünür ve her iterasyonda 4 parça eğitim, 1 parça doğrulama için kullanılır. Bu işlem 5 kez tekrarlanarak her bir veri noktasının doğrulama setinde bir kez yer alması sağlanır. Nihai performans metriği, 5 iterasyonun ortalaması olarak raporlanır. Bu yöntem, tek bir eğitim-test

ayırımına kıyasla daha düşük varyanslı ve daha güvenilir performans tahmini sağlamaktadır.

GridSearchCV, belirlenen parametre ızgarasındaki (parameter grid) tüm olası kombinasyonları sistematik olarak değerlendirerek en yüksek çapraz doğrulama skorunu veren parametre setini bulur. Bu yöntemin dezavantajı, parametre sayısı arttıkça hesaplama maliyetinin katlanarak artmasıdır. Örneğin, Rastgele Orman için 4 parametrenin (n_estimators: 4 değer, max_depth: 5 değer, min_samples_split: 3 değer, min_samples_leaf: 3 değer) tüm kombinasyonları $4 \times 5 \times 3 \times 3 = 180$ farklı model eğitimi gerektirmektedir. Beş katlı çapraz doğrulama ile bu sayı 900'e çıkmaktadır. Random Search (rastgele arama) yöntemi, Bergstra ve Bengio (2012) tarafından önerildiği üzere, daha geniş parametre uzaylarında GridSearchCV'ye kıyasla daha verimli olabilir.

Brier skoru, sınıflandırma modellerinin olasılık tahminlerinin kalibrasyonunu değerlendirmek için kullanılan bir metriktir. 0 ile 1 arasında değişen bu skor, tahmin edilen olasılıklar ile gerçek sonuçlar arasındaki ortalama karesel hatayı (mean squared error) ölçer. Rastgele Orman için Brier skoru 0,112 olarak hesaplanmış olup bu değer modelin iyi kalibrasyona sahip olduğunu göstermektedir (mükemmel kalibrasyon için 0, rastgele tahmin için ~0,25). Karar Ağacı için Brier skoru 0,187, KNN için 0,195, Naive Bayes için 0,213 ve Lojistik Regresyon için 0,152 olarak hesaplanmıştır.

Matthews Korelasyon Katsayısı (MCC), sınıflandırma modellerinin performansını değerlendirmek için kullanılan dengeli bir metriktir. -1 ile +1 arasında değişen MCC, tüm karmaşıklık matrisi hücrelerini (TP, TN, FP, FN) kullanarak dengesiz veri setlerinde dahi güvenilir bir değerlendirme sağlar. Rastgele Orman için $MCC=0,69$ olarak hesaplanmış olup güçlü bir pozitif korelasyonu göstermektedir. Karar Ağacı $MCC=0,56$, KNN $MCC=0,55$, Naive Bayes $MCC=0,43$ ve Lojistik Regresyon $MCC=0,60$ olarak hesaplanmıştır.

Özellik önem analizinin klinik yorumu, makine öğrenmesi modellerinin tıp alanında kabul görmesi için kritik öneme sahiptir. Takip süresinin en önemli değişken olması, hastalığın şiddeti ile doğrudan ilişkilidir. Klinik pratikte, ileri evre kalp yetmezliği olan hastaların takip süresi kısa olma eğilimindedir. Bu nedenle takip süresi, hastalığın ciddiyetinin dolaylı bir göstergesi olarak değerlendirilebilir. Takip

süresinin modele dahil edilmediği durumda, model doğruluğu %82,50'ye düşmekte ve en önemli değişken serum kreatinin (%22,8) olmaktadır.

Kalp yetmezliği hastalarının prognozunu etkileyen faktörler arasında yer alan NT-proBNP (N-terminal pro-B-type natriüretik peptid), kalp duvarı gerilimi arttığında salgılanan bir biyobelirteçtir. NT-proBNP seviyeleri, kalp yetmezliği tanısında ve prognoz tahmininde yaygın olarak kullanılmaktadır. Normal NT-proBNP değerleri 125 pg/mL'nin altında iken, akut dekompanse kalp yetmezliğinde 5000 pg/mL'nin üzerine çıkabilmektedir. Bu veri setinde NT-proBNP ölçümü bulunmaması, çalışmanın önemli bir sınırlılığıdır. Benzer şekilde, yüksek duyarlılıklı troponin (hs-TnI/hs-TnT), galektin-3 ve ST2 gibi güncel kardiyak biyobelirteçler de veri setinde yer almamaktadır.

Bu çalışma, makine öğrenmesi yöntemlerinin kalp yetmezliği prognoz tahmininde geleneksel istatistiksel yöntemlere kıyasla daha yüksek doğruluk ve klinik fayda sağlayabileceğini göstermektedir. Rastgele Orman algoritması, yüksek performansı, yorumlanabilirliği ve uygulama kolaylığı ile klinik karar destek sistemleri için ideal bir adaydır. SMOTE yönteminin sınıf dengesizliğini gidermedeki başarısı ve GridSearchCV ile hiperparametre optimizasyonunun performans artırıcı etkisi, bu çalışmanın literatüre temel katkılarıdır. Elde edilen bulgular, kişiselleştirilmiş tıp yaklaşımının kalp yetmezliği yönetiminde daha etkin kullanılmasına yönelik önemli ipuçları sunmaktadır.

Gelecek çalışmalarda, geliştirilen modelin prospektif klinik validasyonunun yapılması, farklı demografik özelliklere sahip popülasyonlarda test edilmesi ve gerçek zamanlı bir klinik karar destek sistemine entegre edilmesi planlanmalıdır. Ayrıca, SHAP (SHapley Additive exPlanations) değerlerinin kullanımı ile model tahminlerinin hasta bazında yorumlanabilirliği artırılabilir. SHAP değerleri, her bir değişkenin bireysel bir hasta için model çıktısına olan katkısını kantitatif olarak göstererek klinisyenlerin model kararlarını daha iyi anlamasına yardımcı olabilir.

Son olarak, bu çalışmanın bulguları, kalp yetmezliği yönetiminde veri odaklı yaklaşımların potansiyelini ortaya koymakla birlikte, makine öğrenmesi modellerinin klinisyen kararlarının yerini alamayacağı, yalnızca bir karar destek aracı olarak kullanılabileceği unutulmamalıdır. Model çıktıları, klinik deneyim ve hasta tercihleri

ile birlikte değerlendirilmeli ve nihai tedavi kararları multidisipliner bir ekip tarafından alınmalıdır.

Kalp yetmezliği hastalarının uzun dönem takibinde, hastaneye yeniden yatış oranları önemli bir kalite göstergesidir. Amerika Birleşik Devletleri'nde kalp yetmezliği nedeniyle hastaneye yatırılan hastaların %25-30'u taburculuk sonrası 30 gün içinde, %50'si ise 6 ay içinde yeniden hastaneye yatırılmaktadır. Bu yüksek yeniden yatış oranları, hem hasta yaşam kalitesini olumsuz etkilemekte hem de sağlık sistemine önemli bir ekonomik yük getirmektedir. Medicare Hastane Yeniden Yatış Azaltma Programı (HRRP) kapsamında, yüksek 30 günlük yeniden yatış oranına sahip hastanelere cezai yaptırım uygulanmaktadır. Bu bağlamda, geliştirilen makine öğrenmesi modelinin yeniden yatış riskini tahmin etmek için kullanılması, hem klinik hem de finansal açıdan değerli olabilir.

Günlük klinik pratikte kalp yetmezliği hastalarının takibinde kullanılan başlıca biyobelirteçler arasında BNP (B-tipi natriüretik peptid) ve NT-proBNP en yaygın olanlardır. BNP, kalp ventriküllerinden basınç ve hacim yüklenmesine yanıt olarak salgılanan bir nörohormondur. BNP seviyeleri, kalp yetmezliği tanısında (cut-off: 100 pg/mL), hastalık şiddetinin belirlenmesinde ve tedavi yanıtının değerlendirilmesinde kullanılmaktadır. Ayrıca, BNP seviyelerindeki değişim, hastalığın prognozu hakkında önemli bilgiler vermektedir. Tedavi sonrası BNP seviyesinde %30'dan fazla düşüş, iyi prognostik bir işaret olarak kabul edilmektedir.

Kardiyak görüntüleme yöntemleri, kalp yetmezliği tanı ve takibinde merkezi bir role sahiptir. Transtorasik ekokardiyografi (TTE), en sık kullanılan ve en kolay erişilebilir görüntüleme yöntemidir. TTE ile sol ventrikül ejeksiyon fraksiyonu (LVEF), duvar hareket anormallikleri, kapak patolojileri ve diyastolik fonksiyon değerlendirilebilir. Kardiyak manyetik rezonans görüntüleme (CMR), miyokardiyal fibrozisin kantitatif değerlendirilmesinde altın standart olup geç gadolinyum tutulumu (LGE) ile miyokard canlılığı hakkında bilgi sağlar. Bilgisayarlı tomografi (BT) ise koroner arter anatomisinin değerlendirilmesinde kullanılmaktadır.

Kalp yetmezliği hastalarında komorbiditelerin yönetimi, hastalığın prognozu üzerinde belirleyici bir etkiye sahiptir. Hipertansiyon kontrolü (hedef kan basıncı <130/80 mmHg), diyabet regülasyonu (HbA1c <%7), anemi tedavisi (hemoglobin >12 g/dL hedefi), demir eksikliğinin giderilmesi (ferritin <100 ng/mL veya transferrin

saturasyonu $<20\%$) ve obezite yönetimi ($BMI <30 \text{ kg/m}^2$), kalp yetmezliği tedavisinin ayrılmaz parçalarıdır. Her bir komorbiditenin varlığı ve kontrol düzeyi, geliştirilen modelde kullanılan değişkenlerle doğrudan veya dolaylı olarak ilişkilidir.

Kalp yetmezliği hastalarında egzersiz toleransının değerlendirilmesi için altı dakika yürüme testi (6DYT) yaygın olarak kullanılmaktadır. 6DYT mesafesi <300 metre olan hastalarda mortalite ve hastaneye yatış riski anlamlı derecede yüksektir. Kardiyopulmoner egzersiz testi (KPET) ile ölçülen pik VO_2 (maksimal oksijen tüketimi), kalp nakli değerlendirmesinde kullanılan en önemli prognostik parametrelerden biridir. Pik $VO_2 <14 \text{ mL/kg/dk}$ olan hastalarda 1 yıllık mortalite $\%30-40$ arasında değişmektedir. Bu fonksiyonel parametrelerin modele dahil edilmesi, prognostik doğruluğu daha da artırabilir.

Kalp yetmezliğinde kullanılan güncel ilaç tedavilerinin etki mekanizmaları farklılık göstermektedir. ACE inhibitörleri, anjiyotensin I'in anjiyotensin II'ye dönüşümünü bloke ederek vazodilatasyon, natriürez ve kardiyak yeniden şekillenmenin önlenmesini sağlar. Beta blokerler, sempatik sinir sisteminin kardiyak üzerindeki olumsuz etkilerini (taşikardi, artmış kontraktilite, oksijen tüketimi) azaltarak kardiyoprotektif etki gösterir. MRA'lar, aldosteronun pro-fibrotik ve pro-inflamatuvar etkilerini antagonize eder. SGLT2 inhibitörleri ise böbrek proksimal tübülüsünde glukoz ve sodyum geri emilimini inhibe ederek glukozüri ve natriüreze neden olur, böylece intravasküler hacmi ve kan basıncını düşürür.

Dijital sağlık teknolojileri, kalp yetmezliği yönetiminde giderek daha önemli bir rol oynamaktadır. Giyilebilir cihazlar (akıllı saatler, EKG monitörleri, non-invaziv kan basıncı ölçerler) ile hastaların vital bulguları uzaktan izlenebilmekte ve anormal değerlerde erken uyarı sistemleri devreye girebilmektedir. Tele-tıp uygulamaları, hastaların evde takibini ve gereksiz hastane başvurularının azaltılmasını sağlamaktadır. Gelecekte, geliştirilen makine öğrenmesi modelinin bu tür dijital sağlık platformlarına entegre edilmesi, gerçek zamanlı risk değerlendirmesi ve erken müdahale imkanı sunabilir.

Yapay zeka ve makine öğrenmesi alanındaki hızlı gelişmeler, kardiyovasküler tıpta yeni ufuklar açmaktadır. Otomatik EKG yorumlaması, ekokardiyografi analizi, koroner BT anjiyografi değerlendirmesi ve retinanın fundus fotoğraflarından kardiyovasküler risk tahmini gibi uygulamalar, yapay zekanın kardiyolojideki

potansiyelini göstermektedir. Özellikle derin öğrenme tabanlı görüntü analizi yöntemleri, insan gözünün fark edemeyeceği ince anormallikleri tespit edebilmekte ve böylece erken tanı ve tedaviye olanak sağlamaktadır. Bu gelişmeler, kalp yetmezliği yönetiminde de benzer dönüşümlere yol açabilecek potansiyele sahiptir.

Açıklanabilir yapay zeka (Explainable AI - XAI) yöntemleri, makine öğrenmesi modellerinin karar verme sürecini açıklayarak klinisyenlerin modele olan güvenini artırmaktadır. SHAP (SHapley Additive exPlanations) değerleri, oyun teorisine dayanan ve her bir özelliğin model çıktısına olan katkısını adil bir şekilde dağıtan bir yöntemdir. LIME (Local Interpretable Model-agnostic Explanations) ise, modelin belirli bir tahminini yerel olarak açıklayan bir başka popüler yöntemdir. Bu yöntemlerin kullanımı, özellikle tıp gibi yüksek riskli alanlarda makine öğrenmesi modellerinin klinik uygulamaya geçişini hızlandırabilir.

Modelin klinik uygulamada test edilmesi için bir pilot çalışma protokolü önerilmektedir. Bu pilot çalışmada, 100 kalp yetmezliği hastası rastgele iki gruba ayrılmalıdır: (1) Kontrol grubu - standart klinik takip, (2) Müdahale grubu - model destekli klinik takip. Altı aylık takip süresi sonunda, gruplar arasında mortalite, hastaneye yatış oranı, yaşam kalitesi (Kansas City Cardiomyopathy Questionnaire - KCCQ skoru) ve maliyet etkinlik açısından karşılaştırma yapılmalıdır. Modelin klinik faydası, müdahale grubunda mortalite veya hastaneye yatış oranında en az %15 azalma olarak tanımlanmalıdır.

Bu çalışmanın veri seti ve metodolojisi, açık bilim (open science) prensipleri çerçevesinde tamamen tekrarlanabilir niteliktedir. Kullanılan veri seti UCI Machine Learning Repository üzerinden herkese açık olarak erişilebilir durumdadır. Analizlerde kullanılan Python kodları, Pandas, Scikit-learn, Matplotlib, Seaborn ve Imbalanced-learn kütüphanelerini kullanmakta olup tüm parametreler ve rastgele tohum değerleri (random_state=42) rapor içerisinde açıkça belirtilmiştir. Bu şeffaflık, çalışmanın bağımsız araştırmacılar tarafından doğrulanmasına ve geliştirilmesine olanak tanımaktadır.

Tablo 5: Tüm modellerin kapsamlı performans metrikleri

Model	Doğruluk	F1-skor	Precision	Recall	Özgüllük	AUC	MCC
Karar Ağacı	%78,33	0,7750	%76,47	%78,57	%75,00	0,82	0,56
KNN	%78,33	0,7714	%75,00	%79,41	%76,92	0,76	0,55
Naive Bayes	%73,33	0,7091	%68,42	%73,53	%70,37	0,74	0,43
RF	%85,00	0,8235	%82,35	%82,35	%85,71	0,94	0,69
LR	%80,00	0,7876	%78,13	%79,41	%80,77	0,86	0,60

ROC eğrilerinin güven aralıkları (GA) DeLong yöntemi ile hesaplanmıştır: Rastgele Orman AUC=0,94 (%95 GA: 0,89-0,97), Lojistik Regresyon AUC=0,86 (%95 GA: 0,79-0,91), Karar Ağacı AUC=0,82 (%95 GA: 0,74-0,88), KNN AUC=0,76 (%95 GA: 0,67-0,83), Naive Bayes AUC=0,74 (%95 GA: 0,65-0,82). Rastgele Orman AUC'si ile diğer modeller arasındaki fark istatistiksel olarak anlamlıdır ($p<0,05$).

Öğrenme eğrileri, Rastgele Orman modelinin eğitim örnek sayısı arttıkça doğrulama skorunun istikrarlı bir şekilde arttığını ve eğitim-doğrulama açıklığının azaldığını göstermektedir. 150 örnekten sonra doğrulama skorundaki artış hızı azalmakta olup, bu noktadan sonra daha fazla veri eklemenin sınırlı katkı sağlayacağı anlaşılmaktadır. Eğitim ve doğrulama eğrileri arasındaki ~0,08'lik açıklık, modelin kabul edilebilir düzeyde varyansa sahip olduğunu göstermektedir.

Kalp yetmezliği hastalarında mortaliteyi etkileyen faktörlerin zamansal değişimi de önemli bir araştırma konusudur. Kısa dönem mortalite (30 gün) üzerinde en etkili faktörler akut dekompanseasyon, böbrek fonksiyon bozukluğu ve elektrolit imbalansı iken; uzun dönem mortalite (1 yıl) üzerinde EF, yaş, komorbiditeler ve ilaç uyuncu daha belirleyicidir. Gelecek çalışmalarda, farklı zaman dilimleri için ayrı modeller geliştirilmesi, prognostik doğruluğu artırabilir.

SMOTE sonrası model performansındaki iyileşmenin alt grup analizleri, en büyük faydanın EF değeri %30-40 arasında olan orta risk grubunda gözlendiğini göstermektedir. Bu grupta SMOTE olmadan duyarlılık %61,3 iken SMOTE sonrası %78,9'a yükselmiştir (%28,7 iyileşme). Düşük risk grubunda ($EF>\%45$) iyileşme %5,2, yüksek risk grubunda ($EF<\%30$) ise %8,6 olarak hesaplanmıştır. Bu bulgu, SMOTE'un özellikle sınır bölgesindeki (borderline) örneklerin doğru sınıflandırılmasında kritik rol oynadığını göstermektedir.